

Ringkasan

Item	Hasil
Model final untuk reporting	11Z
Final OOF RMSE	11.245635
Model pembanding terdekat	11X, RMSE 11.250966
Model individual terbaik	CatBoostRegressor, RMSE 11.470718
Baseline mean	RMSE 23.192856
Target bin dengan error terbesar	very_high
RMSE pada target bin very_high	19.291652
Bias prediksi pada target bin very_high	-7.173619
Jumlah fitur baru hasil feature engineering	86
Jumlah fitur awal/lama	48
Pasangan fitur berkorelasi tinggi	property_particle_coarse vs property_particle_fine, abs corr 0.902199

Inti: model final sudah lebih baik dari model individual dan baseline, tetapi error terbesar masih ada pada target tinggi.

Tabel

N o	Soal	Tabel atau output yang dipakai	Keterangan
1	Urgensi memprediksi kandungan organik tanah	Final experiment log, Final OOF RMSE	Menunjukkan bahwa target bisa diprediksi cukup baik dibanding baseline, sehingga model punya nilai praktis untuk estimasi cepat.
2	Apakah model overfit atau underfit?	Final experiment log, Overfit / underfit evidence table, Residual by target bin	Membandingkan train RMSE, CV RMSE, train-valid gap, fold std, serta pola error per target bin.
3	Distribusi kandungan organik antar wilayah geografis	Target distribution by geo_zone_macro, geo_zone_meso, geo_zone_micro	Menunjukkan perbedaan mean, median, range, dan variasi target antar level wilayah.
4	Korelasi atau perbedaan antar tingkat wilayah geografis	Geographic hierarchy mean-ratio evidence	Merangkum rasio max/min mean antar macro, meso, dan micro zone.
5a	Rata-rata organik tiap ekosistem saat acidity < P25 dan CEC < mean	Low acidity + low CEC summary by biome, land_cover_type, geo_zone_macro	Menjawab kelompok ekosistem/tutupan lahan/wilayah mana yang punya rata-rata target lebih tinggi pada subset kondisi kimia tertentu.
5b	Kombinasi tutupan lahan dan wilayah geografis sebagai outlier	Land-cover/geography outlier evidence	Menunjukkan kombinasi land cover dan geo zone dengan z-score ekstrem dan flag outlier.
6	Korelasi tinggi dan multicollinearity	High-correlation pairs, abs(corr) >= 0.8	Menunjukkan fitur yang redundan atau sangat berkorelasi.

7	Feature engineering	Feature engineering summary, daftar fitur baru, top feature importance	Menjelaskan jumlah fitur baru dan contoh fitur yang berkontribusi terhadap model.
8	Model yang digunakan	Final experiment log, top feature importance CatBoost/LightGBM/XGBoost	Menjelaskan model individual, ensemble/post-processing, serta bukti performanya.
9	Apakah RMSE tepat?	Residual by target bin, Final OOF RMSE	RMSE cocok sebagai metrik utama, tetapi tabel residual menunjukkan RMSE sensitif terhadap tail dan outlier.
10	Data eksternal yang akan diambil	Tidak ada tabel langsung, dijawab dari konteks domain dan feature gap	Jawaban berupa rekomendasi data tambahan seperti remote sensing, iklim, topografi, dan peta tanah.

Hasil Percobaan

4.1 Final Experiment Log

Rank	Model	Features	Mean CV RMSE	Std CV RMSE	Mean Train RMSE	Train-Valid Gap	Catatan
1	11Z	engineered / post-processed	11.245635	NaN	NaN	NaN	Final selected model for submission/reporting
2	11X	engineered / post-processed	11.250966	NaN	NaN	NaN	Signed dual-tail correction
3	11X robust	engineered / post-processed	11.252014	NaN	NaN	NaN	Safer signed dual-tail correction
4	11O adaptive blend	engineered / post-processed	11.266968	NaN	NaN	NaN	Fold-safe prediction-bin adaptive blending
5	CatBoostRegressor	all engineered features, native categorical	11.470718	0.395977	6.316809	5.153910	Main model with native categorical and missing values
6	XGBoostRegressor	all engineered features, encoded	11.516052	0.309037	4.564849	6.951202	Main model with fold-safe imputation and ordinal encoding
7	LightGBMRegressor	all engineered features, encoded	11.567934	0.311411	3.345722	8.222212	Main model with fold-safe imputation and ordinal encoding
8	HistGradientBoosting Baseline	all engineered features, encoded	12.058976	0.343606	8.226144	3.832832	Tree baseline with fold-safe preprocessing
9	Ridge Baseline	all engineered features, encoded	16.469542	0.317761	16.259431	0.210111	Linear baseline
10	Mean Baseline	target mean only	23.192856	0.485007	NaN	NaN	Predicts each fold training target mean

4.2 Overfit / Underfit Evidence

Model	Mean Train RMSE	Mean CV RMSE	Train-Valid Gap	Std CV RMSE	Interpretasi
11Z	NaN	11.245635	NaN	NaN	Final terbaik berdasarkan OOF, tetapi train gap tidak tercatat untuk post-processing.
11X	NaN	11.250966	NaN	NaN	Hampir setara dengan final, namun sedikit lebih buruk.
11X robust	NaN	11.252014	NaN	NaN	Lebih aman, tetapi performa sedikit di bawah final.
11O adaptive blend	NaN	11.266968	NaN	NaN	Stabil tetapi kalah dari 11Z.
CatBoostRegressor	6.316809	11.470718	5.153910	0.395977	Ada gap cukup besar, indikasi overfit moderat.

XGBoostRegressor	4.564849	11.516052	6.951202	0.309037	Gap besar, indikasi overfit lebih kuat.
LightGBMRegressor	3.345722	11.567934	8.222212	0.311411	Gap paling besar, indikasi overfit paling kuat di model individual.
HistGradientBoosting Baseline	8.226144	12.058976	3.832832	0.343606	Overfit lebih rendah, tetapi performa CV lebih buruk.
Ridge Baseline	16.259431	16.469542	0.210111	0.317761	Tidak overfit, tetapi cenderung underfit karena performa buruk.
Mean Baseline	NaN	23.192856	NaN	0.485007	Baseline sangat lemah.

4.3 Residual by Target Bin

Target Bin	Count	Target Mean	Prediction Mean	Bias Pred - Actual	MAE	RMSE	Max Abs Error	Interpretasi
very_high	2187	71.325513	64.151894	-7.173619	13.487047	19.291652	109.892658	Error terbesar, model underpredict pada target tinggi.
medium	2015	28.526479	29.003593	0.477113	5.811791	9.378989	103.390702	Cukup stabil, ada outlier besar.
high	2152	40.284122	40.196936	-0.087187	6.799592	9.108370	68.328485	Bias hampir nol, performa relatif baik.
very_low	2259	12.766984	17.282442	4.515458	5.003515	7.877215	77.738650	Model overpredict pada target sangat rendah.
low	2597	20.691498	22.288536	1.597037	4.084692	6.442074	63.090516	Bin paling stabil.

4.4 Target Distribution by Geo Zone Macro

Geo Zone Macro	Count	Mean	Median	Std	Min	Max	Range
S	1022	57.266801	55.789674	36.452029	5.382646	191.186425	185.803778
NE	512	42.367177	35.192152	31.220322	3.128191	195.231500	192.103308
MW	2930	34.500503	29.124540	20.587121	5.393433	177.061023	171.667590
N	979	34.394741	30.742570	19.625071	2.479541	148.427285	145.947744
SE	5767	29.089654	24.270450	17.819009	2.157373	181.219360	179.061987

4.5 Geographic Hierarchy Mean-Ratio Evidence

Geographic Level	Number of Groups	Max Group Mean	Min Group Mean	Max/Min Ratio	Std of Group Means	Top Group	Bottom Group
geo_zone_macro	5	57.266801	29.089654	1.968631	10.992168	S	SE
geo_zone_meso	19	72.951594	18.879991	3.863963	16.801795	State_03	State_18
geo_zone_micro	44	108.600016	9.065822	11.979059	20.120699	Loc_031	Loc_065

4.6 Low Acidity + Low CEC Summary

Threshold:

Kondisi	Nilai
property_acidity_index < Q25	12.8805
cation_exchange_capacity < mean	169.1421
Jumlah baris subset	388

By Biome

Biome	Count	Mean	Median	Std	Min	Max	Range
Amazonia	197	27.612371	27.506510	6.731054	11.326210	46.922870	35.596660
Mata Atlantica	186	21.317980	21.034390	10.040505	5.393433	111.644070	106.250637

By Land Cover Type

Land Cover Type	Count	Mean	Median	Std	Min	Max	Range	Catatan
Unknown	19	38.236604	37.214690	5.610481	29.124540	45.304840	16.180300	Mean tertinggi, tetapi count kecil.
Savannah	181	26.549002	25.888480	5.890218	11.326210	46.922870	35.596660	Lebih stabil karena count besar.
Areas of Pioneering Formation	120	22.632195	22.652420	6.775156	9.708180	40.127144	30.418964	Stabil menengah.
Dense Ombrophylous Forest	5	22.328814	19.416360	4.772503	17.798330	27.506510	9.708180	Count sangat kecil.
Seasonal Semideciduous Forest	62	18.685637	16.180300	14.289085	5.393433	111.644070	106.250637	Range besar, ada nilai ekstrem.

By Geo Zone Macro

Geo Zone Macro	Count	Mean	Median	Std	Min	Max	Range	Catatan
NE	4	30.054907	30.499866	11.653093	19.092754	40.127144	21.034390	Mean tertinggi, tetapi count sangat kecil.
N	197	27.612371	27.506510	6.731054	11.326210	46.922870	35.596660	Bukti lebih stabil.
MW	119	22.516451	22.652420	6.696469	9.708180	43.686810	33.978630	Stabil menengah.
SE	68	19.083236	16.180300	13.745252	5.393433	111.644070	106.250637	Range besar.

4.7 Land-Cover + Geography Outlier Evidence, Top Ekstrem

Land Cover Type	Geo Zone	Count	Mean	Median	Std	Range	Z-Score Mean	IQR Outlier	Abs Z > 2	Interpretasi
-----------------	----------	-------	------	--------	-----	-------	--------------	-------------	-----------	--------------

Mixed Ombrophylous Forest	S	83	73.990822	77.843423	32.474257	135.434504	2.032233	True	True	Outlier positif paling kuat dan count masih cukup.
Amazon Rainforest	NE	32	10.225556	8.701406	5.989948	21.304062	-1.957902	False	False	Ekstrem rendah, tetapi tidak melewati abs z > 2.
Areas of Ecological Tension	S	15	71.783362	68.345587	16.576870	50.207471	1.894100	True	False	Outlier positif menurut IQR, count kecil.
Seasonal Deciduous Forest	S	487	71.049993	67.504212	35.850481	184.412273	1.848210	True	False	Outlier positif dengan count besar.
Savannah	S	39	70.739903	67.601293	46.173274	180.435514	1.828806	True	False	Outlier positif, variasi besar.
Areas of Pioneering Formation	MW	188	21.972503	22.652420	8.023551	38.293377	-1.222833	False	False	Kelompok rendah tetapi bukan outlier kuat.
Dense Ombrophylous Forest	SE	262	23.204396	22.652420	9.967143	61.948975	-1.145747	False	False	Rendah relatif terhadap kombinasi lain.
Unknown	SE	464	24.516177	22.652420	12.666913	99.778517	-1.063662	False	False	Rendah relatif, bukan outlier kuat.

4.8 High-Correlation Pairs

Feature 1	Feature 2	Absolute Correlation	Interpretasi
property_particle_coarse	property_particle_fine	0.902199	Korelasi tinggi, indikasi multicollinearity atau redundansi fitur tekstur tanah.

4.9 Feature Engineering Summary

Feature Type	Count
New engineered features	86
Original features	48
Total features after engineering	134

Contoh fitur baru:

Kelompok Fitur	Contoh
Missing indicators	original_total_missing_count, missing_cation_Ca, missing_cation_exchange_capacity
Spectral aggregate	spectral_band_A_mean, spectral_band_A_std, spectral_band_B_mean, spectral_band_B_l2_norm
Soil particle ratio	particle_fine_minus_coarse, particle_fine_ratio, particle_coarse_ratio
Cation interaction	cation_total, fine_x_CEC, Ca_CEC_ratio, Mg_CEC_ratio
Geography / ecosystem interaction	geo_macro_biome, geo_macro_meso__ord, geo_zone_micro_count

4.10 Top Feature Importance, Ringkasan

Model	Top Feature 1	Top Feature 2	Top Feature 3	Pola yang Terlihat
-------	---------------	---------------	---------------	--------------------

CatBoost	source_id, 17.861739	particle_coarse_ratio, 6.289378	spectral_band_A_PC_5, 5.328798	Source/group signal, tekstur tanah, spektral, dan CEC penting.
LightGBM	spectral_band_A_PC_5, 1657.2	spectral_band_A_PC_15, 1597.6	spectral_band_A_PC_6, 1523.4	Spektral sangat dominan.
XGBoost	geo_macro_meso__ord, 0.076995	particle_coarse_ratio, 0.073074	property_particle_coarse, 0.053818	Geografi dan tekstur tanah sangat kuat.

Jawaban Soal

1. Urgensi memprediksi kandungan organik tanah

Prediksi kandungan organik tanah penting karena pengukuran langsung melalui laboratorium dapat memakan biaya, waktu, dan tenaga. Dengan model prediktif, kandungan organik dapat diestimasi lebih cepat dari fitur tanah, spektral, ekosistem, dan geografis. Hal ini berguna untuk prioritas sampling, pemantauan kualitas tanah, pengambilan keputusan pemupukan, dan identifikasi area yang membutuhkan intervensi konservasi.

Bukti dari eksperimen menunjukkan model final **11Z** mencapai **OOF RMSE 11.245635**, jauh lebih baik dibanding **Mean Baseline 23.192856**. Artinya, fitur yang tersedia memang membawa sinyal prediktif yang cukup kuat, bukan sekadar noise.

Tabel utama yang menjawab soal ini: **Final experiment log** dan **Final OOF RMSE**.

2. Overfit atau underfit

Model individual menunjukkan kecenderungan overfit, terutama LightGBM, XGBoost, dan CatBoost, karena train RMSE jauh lebih rendah daripada CV RMSE. LightGBM memiliki train-valid gap paling besar, yaitu **8.222212**, disusul XGBoost **6.951202** dan CatBoost **5.153910**. Ini berarti model belajar sangat baik pada data train, tetapi performanya turun saat divalidasi.

Namun, model final **11Z** dipilih berdasarkan OOF dan post-processing, sehingga evaluasi utamanya adalah validasi OOF. RMSE final **11.245635** lebih baik dari model individual terbaik, yaitu CatBoost **11.470718**. Jadi kesimpulannya, ada indikasi overfit pada model dasar, tetapi ensemble dan post-processing berhasil menurunkan error validasi.

Residual juga menunjukkan kelemahan utama bukan underfit global, melainkan error pada target ekstrem. Bin **very_high** memiliki RMSE **19.291652** dan bias **-7.173619**, artinya model masih cenderung underpredict untuk kandungan organik tinggi.

Tabel utama yang menjawab soal ini: **Overfit / underfit evidence table**, **Final experiment log**, dan **Residual by target bin**.

3. Distribusi kandungan organik antar wilayah geografis

Distribusi kandungan organik berbeda antar wilayah geografis. Pada level **geo_zone_macro**, wilayah **S** memiliki rata-rata target tertinggi sebesar **57.266801**, sedangkan **SE** terendah sebesar **29.089654**. Rasio antara wilayah tertinggi dan terendah pada level macro adalah sekitar **1.97 kali**.

Perbedaan makin besar pada level yang lebih detail. Pada **geo_zone_meso**, rasio max/min mean mencapai **3.863963**, sedangkan pada **geo_zone_micro** mencapai **11.979059**. Ini menunjukkan bahwa faktor spasial/geografis sangat relevan terhadap kandungan organik tanah.

Tabel utama yang menjawab soal ini: **Target distribution by geo_zone_macro**, **Target distribution by geo_zone_meso**, **Target distribution by geo_zone_micro**, dan **Geographic hierarchy mean-ratio evidence**.

4. Korelasi kandungan organik antar tingkat wilayah geografis

Perbedaan mean target antar tingkat wilayah menunjukkan adanya pola geografis bertingkat. Semakin detail level geografisnya, variasi rata-rata target semakin besar. Pada level macro, max/min ratio hanya **1.968631**, tetapi meningkat menjadi **3.863963** pada meso dan **11.979059** pada micro.

Interpretasinya, lokasi yang lebih spesifik menangkap variasi lokal yang tidak terlihat pada level wilayah besar. Hal ini mendukung penggunaan fitur geografis dan interaksi geografis dalam model, seperti macro-zone, meso-zone, micro-zone, serta kombinasi geo dengan biome atau land cover.

Tabel utama yang menjawab soal ini: **Geographic hierarchy mean-ratio evidence**.

5a. Rata-rata organik tiap ekosistem saat acidity < P25 dan CEC < rata-rata

Subset ini menggunakan dua kondisi: **property_acidity_index < 12.8805** dan **cation_exchange_capacity < 169.1421**, dengan total **388 baris**.

Pada level biome, **Amazonia** memiliki rata-rata kandungan organik lebih tinggi, yaitu **27.612371**, dibanding **Mata Atlantica** sebesar **21.317980**. Pada land cover, **Unknown** terlihat paling tinggi dengan mean **38.236604**, tetapi jumlah datanya hanya **19**, sehingga harus dibaca hati-hati. Kelompok yang lebih stabil adalah **Savannah** dengan count **181** dan mean **26.549002**.

Pada geo_zone_macro, **NE** memiliki mean tertinggi **30.054907**, tetapi count hanya **4**. Secara lebih reliabel, **N** lebih kuat karena count **197** dan mean **27.612371**.

Tabel utama yang menjawab soal ini: **Low acidity + low CEC summary by biome, by land_cover_type, dan by geo_zone_macro**.

5b. Kombinasi tutupan lahan dan wilayah geografis sebagai outlier

Kombinasi outlier paling kuat adalah **Mixed Ombrophylous Forest + S** dengan count **83**, mean **73.990822**, dan z-score **2.032233**. Kombinasi ini ditandai sebagai outlier oleh IQR dan juga melewati batas **abs z > 2**, sehingga menjadi bukti outlier positif yang paling kuat.

Beberapa kombinasi lain juga tinggi, seperti **Areas of Ecological Tension + S**, **Seasonal Deciduous Forest + S**, dan **Savannah + S**, tetapi sebagian tidak melewati abs z > 2. Di sisi rendah, **Amazon Rainforest + NE** memiliki mean **10.225556** dan z-score **-1.957902**, tetapi belum melewati abs z > 2.

Tabel utama yang menjawab soal ini: **Land-cover/geography outlier evidence**.

6. Korelasi tinggi dan multicollinearity

Ditemukan satu pasangan fitur dengan korelasi absolut di atas 0.8, yaitu **property_particle_coarse** dan **property_particle_fine** dengan korelasi **0.902199**. Ini menunjukkan adanya multicollinearity atau redundansi antara dua fitur tekstur tanah tersebut.

Dampaknya paling besar untuk model linear, karena koefisien dapat menjadi tidak stabil. Namun model utama yang digunakan, yaitu CatBoost, LightGBM, dan XGBoost, relatif lebih tahan terhadap fitur berkorelasi. Meski begitu, korelasi tinggi tetap perlu dicatat karena bisa memengaruhi interpretasi feature importance.

Tabel utama yang menjawab soal ini: **High-correlation pairs, abs(corr) >= 0.8**.

7. Feature engineering

Feature engineering menghasilkan **86 fitur baru** dari **48 fitur awal**, sehingga total fitur setelah engineering menjadi **134**. Fitur baru mencakup missing indicators, agregasi fitur spektral, rasio partikel tanah, interaksi cation/CEC, serta encoding dan interaksi geografis.

Feature importance menunjukkan bahwa fitur hasil engineering memang berguna. Contohnya, **particle_coarse_ratio** muncul penting pada CatBoost dan XGBoost, sedangkan fitur spektral seperti **spectral_band_A_PC_5** sangat dominan pada LightGBM. Ini menunjukkan bahwa feature engineering membantu model menangkap pola non-linear dari tekstur tanah, sinyal spektral, dan konteks geografis.

Tabel utama yang menjawab soal ini: **Feature engineering summary**, **daftar fitur baru**, dan **top feature importance**.

8. Model yang digunakan

Model utama yang digunakan adalah model tree-based boosting, yaitu **CatBoostRegressor**, **XGBoostRegressor**, dan **LightGBMRegressor**. Model-model ini kemudian dikembangkan menjadi ensemble dan post-processing berbasis OOF. Model final yang dipilih untuk reporting adalah **11Z**.

Alasan penggunaan ensemble adalah performanya lebih baik daripada model individual. Model final mencapai **OOF RMSE 11.245635**, sedangkan CatBoost sebagai model individual terbaik memiliki RMSE **11.470718**, XGBoost **11.516052**, dan LightGBM **11.567934**. Ini menunjukkan ensemble/post-processing memberi peningkatan performa dibanding model tunggal.

Tabel utama yang menjawab soal ini: **Final experiment log** dan **top feature importance CatBoost/LightGBM/XGBoost**.

9. Apakah RMSE tepat?

RMSE tepat digunakan sebagai metrik utama karena menghukum error besar lebih kuat. Untuk prediksi kandungan organik tanah, error besar pada sampel ekstrem bisa berdampak besar terhadap keputusan interpretasi lahan, sehingga penalti yang lebih kuat masuk akal.

Namun, RMSE juga sensitif terhadap outlier dan target ekstrem. Ini terlihat pada bin **very_high**, yang memiliki RMSE **19.291652**, jauh lebih tinggi daripada bin lain. Karena itu, RMSE sebaiknya tetap dilengkapi dengan MAE, bias per bin, dan residual analysis agar interpretasi model tidak hanya bergantung pada satu angka.

Tabel utama yang menjawab soal ini: **Residual by target bin** dan **Final OOF RMSE**.

10. Data eksternal yang akan diambil jika diperbolehkan

Jika data eksternal diperbolehkan, data yang paling berguna adalah:

Data Eksternal	Alasan Digunakan	Contoh Fitur yang Bisa Dibuat
Citra satelit / remote sensing	Menangkap vegetasi, kelembapan, dan kondisi permukaan lahan	NDVI mean, NDVI seasonal, vegetation index
Curah hujan historis	Kandungan organik dipengaruhi iklim dan kelembapan	annual rainfall, dry season length
Suhu historis	Aktivitas biologis dan dekomposisi dipengaruhi suhu	annual temperature mean, heat stress index
Elevasi dan topografi	Topografi memengaruhi erosi, drainase, dan akumulasi bahan organik	elevation, slope, terrain ruggedness
Peta jenis tanah	Memberi konteks tekstur, struktur, dan sifat tanah	soil class, clay content map, drainage class
Penggunaan lahan historis	Riwayat lahan memengaruhi akumulasi organik	crop/forest history, land conversion flag
Biomassa / vegetasi	Vegetasi memengaruhi input bahan organik	biomass index, canopy cover
Data manajemen lahan	Pemupukan, irigasi, dan praktik pertanian memengaruhi target	fertilizer usage, irrigation, tillage practice

Data tersebut dapat diintegrasikan melalui koordinat atau kunci geografis jika tersedia. Jika koordinat tidak tersedia, agregasi per wilayah seperti macro, meso, atau micro zone bisa digunakan sebagai pendekatan.

Tabel utama yang menjawab soal ini: tidak ada tabel langsung dari output, tetapi rekomendasi ini berasal dari gap fitur yang terlihat pada analisis, terutama pentingnya fitur geografis, spektral, dan ekosistem.

Kesimpulan Akhir

Model final **11Z** adalah pilihan terbaik dari eksperimen Section 12 karena memiliki **OOF RMSE terendah 11.245635**. Performa ini lebih baik daripada model individual dan jauh lebih baik daripada baseline mean. Namun, residual analysis menunjukkan kelemahan utama masih berada pada target tinggi, khususnya bin **very_high**, yang cenderung di underpredict.

Secara ilmiah, hasil menunjukkan bahwa kandungan organik tanah dipengaruhi oleh kombinasi fitur tanah, spektral, ekosistem, dan geografi. Bukti terkuat terlihat dari perbedaan mean antar geo zone, outlier kombinasi land cover + region, serta pentingnya fitur spektral dan particle ratio pada feature importance.